

统计模型与 Python 实践课程项目

面向天气冲击与恢复过程的 六专家自适应共享单车需求预测

需求动态、当前天气、恢复记忆与多类时序表示的互补建模

姓名： _____

学号： _____

班级： _____

指导教师： _____

确认实验运行编号： confirmation_final2_20260910_111616

2026 年 9 月 10 日

摘要

本文从一个新的问题发现角度出发：共享单车使用量不是由单一机制产生，而是同时包含需求周期、当前天气、雨后恢复、局部时间模式、递归状态和跨日依赖。若让一个模型同时吸收全部特征和参数，不仅会增加训练复杂度，也可能使强周期信息压制稀疏天气信息。为此，本文保持原研究问题和严格的发布时间边界（issue-time boundary）不变，提出分而专之（divide-and-specialize）的六专家系统：多输出负二项 XGBoost 需求专家、张量样条负二项天气敏感专家（Tensor-Spline Negative-Binomial Weather Expert, TS-NBWE）、多尺度事件恢复负二项专家（Multi-Scale Event-Recovery Negative-Binomial Expert, MSER-NB）、轻量时序卷积网络（Temporal Convolutional Network, TCN）、轻量门控循环单元（Gated Recurrent Unit, GRU）和微型 Transformer（Tiny Transformer）。六个专家都输出未来 $h \in \{1, 2, 3, 6\}$ 小时的完整需求预测；其角色不是把目标机械拆成六部分，而是用六种不同归纳偏置（inductive bias）对同一单车使用过程进行预测和拟合。各候选专家先在自身多种设计中完成前向筛选，再通过 E1 加单专家与去一专家消融（leave-one-expert-out, LOO）辨别独立增量和完全体边际作用，最终最佳配置共同进入状态自适应融合（state-adaptive fusion）。

实验使用 Capital Bikeshare 2023–2025 年官方逐月行程记录聚合得到的 26,130 个可用发布小时，并配对 Open-Meteo 历史天气重建。模型选择和最终评价严格分离：2024 年上半年用于专家校准，2024 年下半年用于融合，2025 年第一季度用于 18 组候选配置筛选（screening），2025 年 4–12 月作为最终评价区间。最终每个时距包含 6,599 个评价小时。以预先规定的均方误差（Mean Squared Error, MSE）融合为主结果，六专家完全体在 1、2、3、6 小时的平均绝对误差（Mean Absolute Error, MAE）分别为 75.691、97.794、116.644 和 129.372，四时距平均 MAE 为 104.875，相对固定 E1 基座降低 31.56%，取得本次已测试方案中的最低综合平均 MAE。LOO 结果显示，移除 E4、E5 后平均 MAE 分别增加 7.519 和 3.383，95% bootstrap 区间均高于零；E2、E3、E6 的总体边际变化较小，但在 shock 或长时距仍呈条件性作用。MSE、MAE、Huber 与状态加权 Huber 的融合敏感性实验表明，开发期差异不足 0.3%，最终期 MSE 仍最低。按状态更新的滚动分位数将 shock 状态 90%/95% 覆盖率由 0.818/0.884 提高到 0.914/0.956，但区间相应变宽，揭示覆盖率（coverage）与锐度（sharpness）的明确权衡。

关键词：共享单车；多专家预测；负二项回归；XGBoost；TCN；GRU；Transformer；天气冲击；恢复过程；预测区间

目录

1	引言	1
1.1	研究背景	1
1.2	研究问题	1
1.3	本文工作与口径调整	1
2	相关方法与建模定位	2
3	数据与问题定义	2
3.1	数据来源与新数据概况	2
3.2	预测任务与发布时间	3
3.3	发布状态	3
3.4	前向时间协议	4
4	六专家完整预测框架 (six-expert full forecasting framework)	4
4.1	共同输出尺度与负二项建模	4
4.2	E1: 需求自身动态贡献	5
4.3	E2: TS-NBWE 当前天气非线性贡献	5
4.4	E3: MSER-NB 多尺度事件恢复贡献	6
4.5	E4: TCN 局部多尺度贡献	7
4.6	E5: GRU 顺序状态贡献	7
4.7	E6: Tiny Transformer 长距离依赖贡献	7
4.8	专家校准、状态融合与预测份额	7
4.9	滚动经验预测区间	8
5	实验设置	8
5.1	候选筛选与完全体训练	8
5.2	评价指标	9
6	单专家增量贡献	9
7	六专家完全体结果	10
7.1	总体点预测	10
7.2	融合目标敏感性	11
7.3	状态分组误差	11
7.4	六专家预测份额	12
7.5	去一专家消融: 完全体中的边际作用	12
8	滚动经验预测区间	13

9 讨论	14
9.1 六个专家各自贡献了什么	14
9.2 原研究问题得到怎样的支持	15
9.3 天气关联与恢复过程的解释边界	15
9.4 为什么保留六专家而不是只保留 E1+TCN	15
10 局限与后续改进	15
11 结论	16
A 完全体状态权重明细	16
B 复现实验输出	17

插图

1	2023-2025 年小时需求与历史天气重建的月度概况。需求季节性和温度季节性高度同步，因此图形只支持描述性关联，不支持因果结论。	3
2	固定 E1 后分别加入一个候选专家的四时距 MAE。E4 和 E5 带来最大整体改善；E2 与 E3 的主要增益集中在 1 小时。	10
3	冻结六专家预测后的融合目标敏感性。图中 final evaluation 只用于报告，不用于选择目标。	11
4	去一专家消融的逐时距总体 MAE 变化。E4 和 E5 在全部时距均保持正边际作用；E6 的作用随时距变化。	13
5	全局残差池（实线圆点）与状态残差池（虚线叉号）的滚动覆盖率。黑色虚线表示名义覆盖。	14

表格

1	配置筛选、校准、融合与最终评价的连续前向切分	4
2	六个专家的独立建模贡献与最终选中配置	5
3	完全体中六个专家的工程规模	8
4	每个候选专家单独加入 E1 后的最终期增量价值	9
5	六专家完全体在最终评价区间的总体点预测结果	10
6	四种融合目标在最终评价期的四时距平均误差	11
7	六专家完全体按发布状态分组的 MAE	11
8	MSE 完全体的全局预测份额 (predictive share)	12
9	去一专家后总体 MAE 的变化 (LOO – full; 正值表示被移除专家有帮助)	12
10	全局与状态分位数区间的四时距平均表现	14
11	六专家在各时距和发布状态下的预测权重	16

1 引言

1.1 研究背景

共享单车需求具有显著的小时周期、工作日节律和季节变化，但在降雨、温度骤变和天气过程刚结束时，单纯依靠固定日历或单一历史滞后往往不足。本文首先从数据生成过程的异质性出发，把“预测并拟合单车使用情况”理解为多个视角共同描述同一完整目标：需求自身、当前天气、事件恢复和不同时间表示各自可能解释不同误差结构。对运营者而言，真正困难的不是证明天气“有影响”，而是在发布时刻 t 只使用当时可获得的信息，预测未来 1、2、3、6 小时的完整需求，并说明不同天气阶段下误差和不确定性如何变化。

原论文通过需求规律、当前天气和动态恢复三个专家建立了这一问题。该思路保留了结构化统计解释，但对复杂局部时序、递归记忆和长距离依赖的表达有限。另一种直接做法是构造一个“全特征单模型”，让同一模型同时接收全部需求、天气、事件和长窗口序列。本文识别出的关键问题不是缺少某一种更大的算法，而是异质机制在单一参数空间内发生表示竞争：高频且稳定的日周周期容易主导优化，稀疏的降雨冲击与短暂恢复信息则可能被平均掉；同时，长窗口、交互项与多时距输出会迅速扩大训练复杂度。本文据此重新定义建模单元，让每个专家以自身信息边界和归纳偏置独立预测同一完整需求，再由低维融合层组合。这一“问题发现与问题设定”（problem discovery and formulation）构成本文的主要创新点之一。当前实验没有单独训练全特征单模型，因此关于单体复杂度的论述是可检验的设计动机，而不是已被对照实验确认的普遍性能结论。本文在原有三种视角上增加 TCN、GRU 和 Tiny Transformer 三个轻量时序专家，并统一改为 $h \in \{1, 2, 3, 6\}$ 的四时距输出。

1.2 研究问题

本文回答以下四个问题：

1. 在严格的发布时间边界（issue-time boundary）下，需求自身动态、当前天气和天气历史分别能否提供可验证的增量信息？
2. 局部卷积、递归状态和注意力三种时序归纳偏置，是否能补充结构化统计专家遗漏的模式？
3. 六个完整预测经过校准和状态自适应融合后，在正常、冲击和恢复状态下表现如何？
4. 点预测之外，滚动经验预测区间在哪些状态下可靠，在哪些状态下仍然不足？

1.3 本文工作与口径调整

本文的主要工作不是提出新的树算法或深度网络，而是建立一个可审计的多视角统计预测流程：

- 提出分而专之（divide-and-specialize）的建模视角，以多个小型完整预测器代替一个吞并全部参数的单体模型；
- 保留固定的 E1 多输出负二项 XGBoost，只把输出时距更新为 1、2、3、6 小时；
- 为 E2–E6 分别准备多种候选设计，通过开发期筛选确定每类专家的最佳配置，再以 E1 加单专家评估增量能力，并以 LOO 重新拟合完整系统，区分“单独能贡献什么”和“在其余专家均存在时是否仍不可替代”；
- 使用最终评价区间之前的数据完成配置筛选、专家校准和融合权重学习；

- 在完全体（full model）中保留全部六个专家，但不再强制每个权重至少为 10%。当前实现采用 softmax 非负权重，因此无效专家可以得到接近零的预测份额（predictive share）；
- 将“天气效应”统一表述为条件关联，将融合权重统一表述为预测份额，不进行因果或机制强度外推；
- 对 MSE、MAE、Huber 和状态加权 Huber 融合目标进行开发期敏感性比较，并以状态分位数和事件簇 bootstrap 重新检查冲击区间；
- 在最新六专家预测上重新生成数据图、增量消融图、LOO图、融合目标图和状态区间图。

2 相关方法与建模定位

梯度提升树通过逐步拟合损失函数的负梯度构造加法模型 [1]，XGBoost 在正则化和工程实现上进一步提高了可扩展性 [2]。本文的 E1 使用 XGBoost 的多输出树接口，并以负二项计数似然构造自定义目标。负二项模型允许方差随均值二次增长，适合小时需求中常见的过度离散 [3]。

结构化天气专家借鉴广义加性模型的低自由度平滑思想 [4]，恢复专家则使用多个指数衰减尺度表达事件结束后的持续关联。深度时序部分分别采用 TCN 的因果膨胀卷积 [5]、GRU 的门控递归状态 [6] 和 Transformer 的自注意力结构 [7]。这些网络均控制在 8 万参数以内，其目的不是替代结构化统计解释，而是检验不同时间表示是否提供互补预测误差。

多专家融合与经典专家混合（mixture-of-experts）思路一致 [8, 9]，但本文不训练复杂门控网络（gating network），而是在预先定义的发布状态内学习低维非负权重。预测区间使用按发布时间顺序更新的经验残差分位数；它与保形预测（conformal prediction）的残差校准思想相关 [10]，但由于配置筛选与初始残差池并非完全独立，本文不宣称严格的有限样本覆盖保证。

3 数据与问题定义

3.1 数据来源与新数据概况

需求来自 Capital Bikeshare 官方发布的 2023–2025 年 36 个逐月行程压缩包 [11]。每条行程按出发时间聚合为全系统小时出发量。天气来自 Open-Meteo 历史天气接口的小时重建 [12]，包含温度、相对湿度、降雨和风速。该天气数据是回溯代理，不等同于当时实际发布的天气预报，因此本文评价的是严格历史信息边界下的回溯建模能力，不直接代表线上天气预报系统的业务表现。

经过 UTC 统一、夏令时处理、完整小时索引、滞后构造和四时距标签对齐后，得到 26,130 个可用发布小时，覆盖 2023-01-08 05:00 UTC 至 2025-12-31 22:00 UTC，总出发量为 17,189,278。数据中发布时降雨小时为 3,507，在线解析得到 649 个雨事件编号和 450 个评价事件簇。




图 1: 2023–2025 年小时需求与历史天气重建的月度概况。需求季节性和温度季节性高度同步，因此图形只支持描述性关联，不支持因果结论。

3.2 预测任务与发布时间

在小时 t 的出发量聚合完成后发布预测，目标为

$$Y_{t+h}, \quad h \in \{1, 2, 3, 6\}. \quad (1)$$

可用信息集合记为 $\mathcal{F}_t$ 。所有需求、天气和事件变量只能使用到 t ；目标小时、星期、月份、节假日等日历变量可提前知道。任何包含 Y_{t+h} 的训练行只有在最晚标签 Y_{t+6} 到达后才能进入训练集。模型输出

$$\hat{\mu}_{t,h} = \mathbb{E}(Y_{t+h} \mid \mathcal{F}_t). \quad (2)$$

3.3 发布状态

状态由发布时可见的在线雨事件解析器产生：

- **正常状态 (normal)**：发布时无进行中的降雨，且不在已确认事件后的恢复窗口；
- **冲击状态 (shock)**：发布时降雨正在进行；
- **恢复状态 (recovery)**：最近雨事件已经结束，且发布时仍处于预设恢复窗口。

状态只决定融合权重，不使用目标时刻的真实天气，也不利用未来事件结束时间或未来累计雨量。

3.4 前向时间协议

表 1: 配置筛选、校准、融合与最终评价的连续前向切分

阶段	发布时段	每时距样本	用途
校准拟合 (calibration fit)	2024-01 至 2024-06	4,368	拟合每个专家的低维偏差校准
融合拟合 (fusion fit)	2024-07 至 2024-12	4,416	学习全局及三状态融合权重
筛选开发 (screening dev)	2025-01 至 2025-03	2,160	在 18 组候选中选择每类专家配置
最终评价 (final evaluation)	2025-04 至 2025-12	6,599	固定配置后的最终回溯评价

这种切分使最终评价不参与结构和超参数选择。补充确认实验复用已经冻结的六专家逐时预测，只重新拟合校准层、融合层和结构化 E3 变体；因此所有目标比较和 LOO 都保持同一专家预测输入，不通过最终评价期重新选择结构。

4 六专家完整预测框架 (six-expert full forecasting framework)

4.1 共同输出尺度与负二项建模

六个专家都对同一完整目标建模。多专家的目的不是减少输入信息总量，而是把异质信息和归纳偏置分配给不同的小型学习器，降低单个模型同时拟合所有机制的负担。对于专家 k ,

$$Y_{t+h} | \mathcal{F}_t \sim \text{NB}(\mu_{t,h}^{(k)}, \alpha_h^{(k)}), \quad \text{Var}(Y_{t+h} | \mathcal{F}_t) = \mu_{t,h}^{(k)} + \alpha_h^{(k)} (\mu_{t,h}^{(k)})^2. \quad (3)$$

深度专家共享一个时序骨干网络 (temporal backbone), 并设置四个时距输出头 (horizon heads)。结构化专家按时距拟合, E1 则通过一个多输出树联合生成四维对数均值。

表 2: 六个专家的独立建模贡献与最终选中配置

ID	最终配置	专属贡献	主要输入和归纳偏置
E1	Multi-output NB-XGBoost	需求自身动态与四时距联合基座	需求滞后、差分、滚动统计、目标日历；不直接输入天气
E2	spline_only	当前天气的可解释非线性响应	发布时温度、降雨、湿度、风速的三次样条与公共控制
E3	multi_scale	已结束雨事件的多尺度恢复记忆	事件累计雨量在 $\tau = 3, 12, 36$ 小时尺度的衰减及在线事件字段
E4	TCN, $L = 72$, 32 通道, 3 块	局部因果、多尺度卷积模式	72 小时需求-天气序列, 膨胀率 1, 2, 4
E5	GRU, $L = 72$, 隐藏维 64, 1 层	递归隐状态与顺序记忆	72 小时需求-天气序列, 单层门控递归
E6	Transformer, $L = 168$, $d = 32$, 1 层, 2 头	跨较远时刻的直接依赖	168 小时序列、可学习位置编码与轻量自注意力

4.2 E1: 需求自身动态贡献

E1保留原论文的多输出负二项 XGBoost。输入包含 0, 1, 2, 3, 6, 24, 48, 168 小时需求滞后、短期变化量、3/24/168 小时滚动均值和 24 小时滚动波动, 以及四个目标时刻的日历特征。模型联合输出

$$\boldsymbol{\eta}_t = (\eta_{t,1}, \eta_{t,2}, \eta_{t,3}, \eta_{t,6}), \quad \mu_{t,h}^{(1)} = \exp(\eta_{t,h}). \quad (4)$$

E1 的贡献是提供只依赖需求自身变化和周期规律的强基座。它不能解释为“无天气时的反事实需求”, 因为历史需求本身已经包含过去天气影响。

4.3 E2: TS-NBWE 当前天气非线性贡献

E2 定义为张量样条负二项天气敏感专家 (Tensor-Spline Negative-Binomial Weather Expert, TS-NBWE)。它只回答一个窄而清晰的问题: 在发布时刻 t 已经观测到的天气条件下, 未来完整需求均值如何呈现非线性变化。E2 不读取历史天气序列、未来天气或尚未结束事件的未来总雨量, 因而与 E1 的需求惯性、E3 的历史恢复记忆保持输入角色上的分离。

为防止天气变量在有限冲击样本上产生高自由度拟合, 连续变量均采用低自由度三次 B 样条 (cubic B-spline)。公共控制 $\mathbf{c}_{t,h}$ 只包含目标日历、发布小时与基本通勤标记, 用来吸收可预知的时段差异。基础配置为

$$\log \mu_{t,h}^{(2)} = \mathbf{c}_{t,h}^\top \boldsymbol{\beta}_h + s_T(T_t) + s_R(\log(1 + R_t)) + s_H(H_t) + s_V(V_t), \quad (5)$$

其中 T_t, R_t, H_t, V_t 分别表示发布时温度、雨量、湿度与风速。负二项对数似然使模型直接适配计数需求的过度离散, 而样条基函数允许冷、热、小雨和强降雨附近具有不同局部斜率; 这些曲线仍表示条件关联 (conditional association), 不解释为天气的因果处理效应。

E2 的候选设计逐层增加交互复杂度。spline_only 只含式 (5); spline_th 增加温度-湿度张量项 $s_{TH}(T_t, H_t)$; full_tensor 再加入雨量-风速张量项 $s_{RV}(R_t, V_t)$ 与通勤时段雨量响应。

三种方案的开发期相对选择分数分别为 0.877039、0.877200 和 0.879186，数值越小越好。最简单的 `spline_only` 以很小优势胜出，说明本数据上的主要收益来自稳定的一维平滑，而不是更高阶天气交互。这个选择也体现本文的复杂度纪律：专家的任务是提供一种明确视角，而不是在每个专家内部再次堆叠所有可能参数。

E2 的“自己的贡献”有三个层次：建模上，它给出发布时天气的低维光滑响应；实验上，它在 E1 加单专家比较中主要改善 1 小时预测；融合上，它在 `shock` 的短时预测中保留条件性份额。三者共同支持“当前天气是短时校正专家”的定位，但不支持把 E2 表述为所有时距的主预测器。

4.4 E3: MSER-NB 多尺度事件恢复贡献

E3 定义为多尺度事件恢复负二项专家 (Multi-Scale Event-Recovery Negative-Binomial Expert, MSER-NB)。它关注的不是当前下雨本身，而是发布时已经发生的降雨历史如何与之后的需求恢复相联系。在线事件解析器在每个发布时刻更新事件是否进行、已持续时长、截至当前的累计雨量，以及最近一个已结束事件的可确认摘要；任何未来雨停时间、最终事件总量或目标时刻真实天气均不可见。

对最近已结束事件，记累计雨量、持续时长和雨停后经过时间为 C_t, D_t, S_t 。为避免预先假定唯一恢复速度，E3 构造三个衰减尺度：

$$E_{t,h}^{C,\tau} = \log(1 + C_t) \exp\left[-\frac{\min(S_t + h, 72)}{\tau}\right], \quad (6)$$

$$E_{t,h}^{D,\tau} = \log(1 + D_t) \exp\left[-\frac{\min(S_t + h, 72)}{\tau}\right], \quad \tau \in \{3, 12, 36\}. \quad (7)$$

$\tau = 3$ 描述快速回弹， $\tau = 12$ 描述日内恢复， $\tau = 36$ 则允许影响跨越一个自然日。该设计把“雨后恢复”从固定 12 小时窗口改为可由数据组合的多时间尺度表示，同时保证式中每一项都能在发布时计算。

除事件摘要外，候选设计还测试连续雨历史记忆：

$$M_{t,h}^{\tau} = \sum_{\ell=1}^{72} \log(1 + R_{t-\ell}) \exp\left[-\frac{\ell + h}{\tau}\right], \quad \tau \in \{3, 12, 36\}. \quad (8)$$

这里的 $M_{t,h}^{\tau}$ 不需要把历史小时硬切成单一雨事件，可表达多段小雨或间歇降雨的累积记忆。候选 `multi_scale` 使用式 (7) 的已结束事件摘要；`memory` 加入式 (8)；`full` 再加入事件持续时长及累计雨量-时长交互。初始开发期相对选择分数依次为 0.887374、0.887571 和 0.887576，最终按开发期规则选择结构更简单的 `multi_scale`。

补充确认中另构造 `history_only`：移除当前天气与进行中降雨字段，只保留公共控制、已结束事件摘要和连续历史记忆。四种 E3 设计在最终期的四时距平均 MAE 为 104.875–104.888，恢复状态为 106.741–106.767，差异很小。因此正文继续采用事先冻结的 `multi_scale`，不根据最终期的微小差异改选配置。E3 的贡献应准确表述为“对已发生事件历史的多尺度恢复表示，以及在 `shock`/较长时距中的条件性补充”，不能扩大为独立识别的因果恢复效应。

4.5 E4: TCN 局部多尺度贡献

E4 读取过去 72 小时的需求、温度、降雨、湿度、风速、冲击/恢复指示、事件持续字段和周期编码。三层因果卷积块的膨胀率为 1, 2, 4，每块采用残差连接：

$$z^{(l)} = z^{(l-1)} + \text{Dropout}\{\text{ReLU}(\text{Conv}_{d_l}(z^{(l-1)}))\}. \quad (9)$$

E4 的贡献是学习人工滞后和事件衰减没有直接指定的局部、多尺度时序形状。最终配置包含 9,956 个参数。

4.6 E5: GRU 顺序状态贡献

E5 使用与 E4 相同的 72 小时序列字段，但将历史压缩为门控递归状态：

$$h_t = \text{GRU}(x_{t-71:t}), \quad \eta_t = W h_t + b. \quad (10)$$

其独立贡献是检验显式递归状态是否适合表示需求和天气过程的顺序累积。最终配置为单层、隐藏维度 64，共 15,812 个参数。

4.7 E6: Tiny Transformer 长距离依赖贡献

E6 采用 168 小时窗口，每小时构成一个需求-天气-事件词元 (token)。线性投影和可学习位置编码后，通过一层双头 Transformer 编码器 (encoder)：

$$Z = \text{Encoder}(XW_e + P), \quad \eta_t = W_o Z_t + b_o. \quad (11)$$

E6 的贡献是允许一周窗口内相隔较远的时间点直接交互，而不依赖卷积层数或递归传递。最终配置 $d_{\text{model}} = 32$ 、FFN=64、1 层、2 头，共 14,564 个参数。

4.8 专家校准、状态融合与预测份额

每个专家先在 calibration fit 上进行低维偏差校准：

$$\tilde{\mu}_{t,h}^{(k)} = \max\{0, a_{k,h} + b_{k,h}\mu_{t,h}^{(k)}\}. \quad (12)$$

在 fusion fit 上学习全局权重，再对每个状态学习向全局权重收缩的状态权重：

$$\hat{\mu}_{t,h}^{(F)} = \sum_{k=1}^6 w_{h,s_t,k} \tilde{\mu}_{t,h}^{(k)}, \quad (13)$$

$$\min_{\mathbf{w}} \quad \frac{1}{n_s} \sum_{t:s_t=s} \left(Y_{t+h} - \sum_{k=1}^6 w_k \tilde{\mu}_{t,h}^{(k)} \right)^2 + \lambda \|\mathbf{w} - \mathbf{w}_h^{(G)}\|_2^2, \quad (14)$$

$$\text{s.t.} \quad w_k \geq 0, \quad \sum_{k=1}^6 w_k = 1. \quad (15)$$

实现中使用 softmax 参数化保证约束，并取 $\lambda = 0.5$ 。因此“六个专家都被纳入完全体 (full model)”不等于“每个专家必须拿到固定最低份额”；接近零的权重表示融合器对当前状态下预测作用的收缩。权重只表示特定时距和状态下的预测组合份额 (predictive share)，不是天气或需求机制的因果贡献率。

4.9 滚动经验预测区间

对完整融合预测定义异方差归一化残差

$$r_{t,h} = \frac{|Y_{t+h} - \hat{\mu}_{t,h}^{(F)}|}{\max\{\sqrt{\hat{\mu}_{t,h}^{(F)}}, 25\}}. \quad (16)$$

在发布时刻 t ，只纳入目标时间不晚于 t 的既往残差，并保留最近 2,160 个分数。令 $q_{t,h,\gamma}$ 为经验 γ 分位数，则

$$\left[\max\{0, \hat{\mu}_{t,h}^{(F)} - q_{t,h,\gamma} s_{t,h}\}, \hat{\mu}_{t,h}^{(F)} + q_{t,h,\gamma} s_{t,h} \right], \quad s_{t,h} = \max\{\sqrt{\hat{\mu}_{t,h}^{(F)}}, 25\}. \quad (17)$$

该区间是随时间更新的经验不确定性描述。由于初始分数池来自已经参与配置筛选的开发期，它不具备严格的分布无关覆盖保证。

5 实验设置

5.1 候选筛选与完全体训练

E1 是固定需求基座，不参与结构搜索。E2 和 E3 各测试 3 个结构化配置；E4、E5、E6 各测试 4 个轻量配置，共 18 组。第一步是在每类专家自己的多种设计角度中，使用 2025 年第一季度开发期选择最佳配置。第二步只比较 E1、E1+E2、E1+E3、E1+E4、E1+E5、E1+E6，以消融实验识别每个专家相对固定基座的独立增量价值。第三步将六类专家各自的最佳配置重新训练并共同放入完全体融合，完成总的预测拟合。

在冻结上述配置后，补充确认实验执行四项检查。第一，分别移除 E2–E6，并对剩余专家重新拟合校准与融合，得到去一专家消融 (leave-one-expert-out, LOO)；E1 作为问题基座始终保留。第二，只用 screening dev 比较 MSE、MAE、Huber 和状态加权 Huber 的融合敏感性，final evaluation 不参与选择。第三，分别以统一残差池和 normal/shock/recovery 状态残差池构造滚动分位数。第四，重拟合 E3 的四种结构变体，检查结论是否依赖单一事件表示。深度专家预测保持冻结，不在确认实验中改变网络或随机种子。

当前正式运行使用 PyTorch 2.14.0 CPU 版本，device=cpu，自动混合精度 (Automatic Mixed Precision, AMP) 未启用。因而本文不再沿用旧论文“使用 RTX 4060/CUDA”的实现口径。深度模型参数规模和窗口仍符合单卡友好设计，但本轮工程时间只能解释为本机 CPU 实测。

表 3: 完全体中六个专家的工程规模

专家	参数量	训练时间/s	推理时间/s	峰值 GPU 显存/MB
E1 NB-XGBoost	—	—	—	—
E2 spline_only	—	—	—	—
E3 multi_scale	—	—	—	—
E4 TCN	9,956	219.987	0.225	0
E5 GRU	15,812	392.004	0.935	0
E6 Tiny Transformer	14,564	1,661.360	1.015	0

结构化专家的计时字段在当前运行中被记录为 0，而非真实零耗时，因此表中改记为“-”。这也是本文重新规划结果口径的一部分：缺失的工程测量不作数值性结论。

5.2 评价指标

点预测使用

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (18)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (19)$$

同时按正常（normal）、冲击（shock）、恢复（recovery）分组。区间报告经验覆盖率和平均宽度。LOO 定义

$$\Delta \text{MAE}_{-k} = \text{MAE}(\mathcal{E} \setminus \{k\}) - \text{MAE}(\mathcal{E}), \quad (20)$$

正值表示专家 k 在其余专家均存在时仍能降低误差。正常与总体样本使用 7 日历周块 bootstrap，shock/recovery 使用事件簇 bootstrap，均重复 500 次并报告 95% 区间。该口径不同于 E1 加单专家：前者测“完全体中的边际不可替代性”，后者测“相对固定基座的独立增量能力”。

6 单专家增量贡献

表 4: 每个候选专家单独加入 E1 后的最终期增量价值

模型	1h MAE	2h MAE	3h MAE	6h MAE	平均 MAE	相对 E1 改善
E1 only	130.964	143.024	165.942	173.002	153.233	—
E1+E2 Weather	105.030	144.064	168.051	182.537	149.921	2.16%
E1+E3 Recovery	104.626	143.407	166.750	179.929	148.678	2.97%
E1+E4 TCN	78.756	99.890	118.169	129.846	106.665	30.39%
E1+E5 GRU	80.401	104.157	122.759	140.543	111.965	26.93%
E1+E6 Transformer	106.175	121.432	138.529	148.851	128.747	15.98%




图 2: 固定 E1 后分别加入一个候选专家的四时距 MAE。E4 和 E5 带来最大整体改善；E2 与 E3 的主要增益集中在 1 小时。

表 4 直接回应“每个专家自己的贡献”。E2 将 1 小时 MAE 降低约 19.80%，但在 2-6 小时略有恶化，因此其价值更接近短时天气校正。E3 的模式相似，1 小时改善约 20.11%，长时距优势不足。E4 在全部时距都显著改善，是最强的单一增量专家；E5 次之；E6 虽弱于 TCN 和 GRU，但仍在四个时距提供一致改善。这些结论来自 E1 加单专家的完整重训和融合，而不是从完全体权重反推。

7 六专家完全体结果

7.1 总体点预测

表 5: 六专家完全体在最终评价区间的总体点预测结果

时距/h	样本数	MAE	RMSE	目标均值
1	6,599	75.691	117.124	815.271
2	6,599	97.794	156.000	815.286
3	6,599	116.644	187.735	815.291
6	6,599	129.372	203.462	815.376

四时距平均 MAE 为 104.875，相对 E1-only 的 153.233 降低 31.56%，并取得本次已测试配置中的最佳综合平均表现（best overall average）。因此，本文所说的“best of all”严格指已测试方案中的四时距平均 MAE 最低，不能解释为每个专家都有同等权重或在每个状态都不可替代；更准确的结论是六种候选视角经过筛选与收缩后，完整融合在综合平均意义上获得了最优拟合。

7.2 融合目标敏感性

原设计以 MSE 学习融合权重，而正文主要报告 MAE。为检查两种口径是否冲突，确认实验在不改变专家预测的前提下比较四种融合目标。MAE 目标在 screening dev 的综合选择分数为 0.997065，相对 MSE 的 1.000000 仅改善 0.294%；状态加权 Huber 为 0.998391，普通 Huber 为 1.000319。这个量级不足以支持更换主方案，故保持事先规定的 MSE 作为主结果，并把其余目标作为敏感性分析。

表 6: 四种融合目标在最终评价期的四时距平均误差

融合目标	平均 MAE	平均 RMSE
MSE（主结果）	104.875	166.080
MAE	105.167	166.670
Huber	105.131	166.611
状态加权 Huber	105.274	166.604




图 3: 冻结六专家预测后的融合目标敏感性。图中 final evaluation 只用于报告，不用于选择目标。

7.3 状态分组误差

表 7: 六专家完全体按发布状态分组的 MAE

发布状态	样本数/时距	1h	2h	3h	6h
正常（normal）	3,074	66.527	84.260	101.204	111.791
冲击（shock）	1,018	102.785	137.129	158.274	171.169
恢复（recovery）	2,507	75.925	98.417	118.672	133.956

冲击状态在所有时距下最难，四时距平均 MAE 为 142.339；恢复状态为 106.743，正常状态为 90.945。天气冲击不仅提高点误差，也要求后续区间校准使用与正常状态不同的误差尺度。

7.4 六专家预测份额

表 8: MSE 完全体的全局预测份额 (predictive share)

h	E1	E2	E3	E4	E5	E6
1	0.036	0.094	0.000	0.271	0.469	0.130
2	0.000	0.000	0.000	0.406	0.254	0.341
3	0.000	0.007	0.000	0.331	0.251	0.411
6	0.000	0.000	0.010	0.307	0.275	0.408

全局权重显示：1 小时主要由 E5、E4 和 E6 构成，同时 E2 保留 0.094；2 小时主要由 E4、E6 和 E5 构成；3 小时和 6 小时的最大全局份额均为 E6。状态权重受到 $\lambda = 0.5$ 的全局收缩，变化比初始运行更平稳：1h shock 的 E2 为 0.100，3h shock 的 E3 为 0.012，6h shock 的 E3/E6 分别为 0.028/0.415。由此，权重只说明融合器在给定状态下如何组合预测，不能单独证明专家的不可替代性；后者应以 LOO 为主。

7.5 去一专家消融：完全体中的边际作用

E1 加单专家实验说明每种视角相对需求基座能做什么，但它不能回答“其余五个专家都存在时，某个专家是否仍然必要”。表 9 因此报告对 E2–E6 逐一移除、重新拟合校准与融合后的误差变化。

表 9: 去一专家后总体 MAE 的变化 (LOO – full; 正值表示被移除专家有帮助)

移除专家	1h	2h	3h	6h	四时距平均
E2 TS-NBWE	-0.066	-0.006	-0.079	-0.010	-0.040
E3 MSER-NB	0.002	-0.009	0.015	-0.030	-0.006
E4 TCN	5.157	9.591	7.119	8.208	7.519
E5 GRU	5.429	2.886	2.982	2.236	3.383
E6 Transformer	-0.957	-1.444	-0.882	1.475	-0.452




图 4: 去一专家消融的逐时距总体 MAE 变化。E4 和 E5 在全部时距均保持正边际作用；E6 的作用随时距变化。

E4 的四个时距 95% 周块 bootstrap 区间分别为 $[4.368, 5.929]$ 、 $[7.977, 11.347]$ 、 $[5.369, 8.616]$ 和 $[6.281, 10.157]$ ；E5 分别为 $[4.278, 6.327]$ 、 $[2.293, 3.569]$ 、 $[2.104, 3.877]$ 和 $[0.508, 3.844]$ ，均完全高于零。这使“TCN 与 GRU 是完全体核心贡献者”得到比融合权重更直接的证据。E2、E3 的总体变化接近零，表明融合层可以在全专家池内吸收其平均作用；但 E2 在 shock 的平均变化为 0.096，E3 为 0.016，仍可作为结构化解释视角。E6 在 1-2 小时移除后反而略有改善，在 6 小时和 shock 的 3 小时呈正作用；因此它应称为长时距/复杂状态的条件性专家，而不是全局稳定增益源。

8 滚动经验预测区间

统一滚动分位数的总体覆盖接近名义水平，但它把 normal 的低波动与 shock 的高波动放在同一个残差池中，导致正常状态偏宽、冲击状态偏窄。补充实验保持完全相同的 issue-time 更新规则，只把历史残差按发布状态分别入池；当某状态早期样本不足时回退到全局池，避免使用未来分数。

表 10: 全局与状态分位数区间的四时距平均表现

方法	状态	90% 覆盖	90% 宽度	95% 覆盖	95% 宽度
全局 (global)	overall	0.900	436.943	0.949	580.694
全局 (global)	normal	0.927	425.948	0.968	563.630
全局 (global)	shock	0.818	448.754	0.884	597.433
全局 (global)	recovery	0.900	445.628	0.951	594.819
状态分位数	overall	0.907	454.287	0.955	595.722
状态分位数	normal	0.905	383.663	0.956	497.483
状态分位数	shock	0.914	683.510	0.956	892.663
状态分位数	recovery	0.907	447.803	0.954	595.604




图 5: 全局残差池 (实线圆点) 与状态残差池 (虚线叉号) 的滚动覆盖率。黑色虚线表示名义覆盖。

状态分位数将 shock 的平均 90% 覆盖从 0.818 提高到 0.914, 将 95% 覆盖从 0.884 提高到 0.956; 事件簇 bootstrap 的各时距结果同样支持覆盖改善。与此同时, shock 平均宽度分别增加 52.3% 和 49.4%。因此该实验补齐了“冲击欠覆盖”的主要缺口, 却不是无代价的胜利: 更可靠的极端状态覆盖来自更宽的区间。对 normal 状态, 状态分位数还把 90% 平均宽度从 425.948 降至 383.663, 同时覆盖由过度保守的 0.927 调整到 0.905, 显示分状态校准能够同时改善正常期锐度和冲击期覆盖。

9 讨论

9.1 六个专家各自贡献了什么

E1 提供需求惯性和日周周期基座, 是所有增量比较的固定参照; 它在完全体平均权重较小, 不等于它在实验设计中不重要。E2 通过 TS-NBWE 给出可解释的发布时天气非线性, 主要价值集中在短时冲击。E3 通过 MSER-NB 将原固定 12 小时恢复尺度扩展到 3、12、36 小时, 并用已结束事件与连续历史记忆描述恢复过程。E4 用因果膨胀卷积提供最强且最稳定的边际改善。E5 用门控递归状态在全部时距保持正贡献。E6 用一周窗口注意力补充较长时距和复杂状态, 但其

总体增益并非单调。

因此，“每个专家有自己的贡献”应包含三个层次：第一，结构层面每个专家具有不同的信息视角或时序归纳偏置；第二，E1 加单专家说明该视角相对需求基座能否独立改善；第三，LOO 与条件权重说明它在完整专家池中的边际作用。不能仅凭专家名称假定其一定有效，也不能把接近零的权重改写成显著贡献。

9.2 原研究问题得到怎样的支持

第一，需求历史、当前天气和恢复事件都能在特定时距提供预测信息，但结构化天气/恢复的单专家增量主要集中在 1 小时。第二，三种学习型时序专家都能相对 E1 改善，其中 TCN 的单专家增量最大；进一步的 LOO 表明 E4、E5 是完全体中最稳定的边际贡献者。第三，六专家完全体取得最低四时距平均 MAE，但 E2、E3、E6 的完全体边际作用具有状态或时距条件，说明“纳入专家”与“始终不可替代”不是同一命题。第四，状态分位数基本修复 shock 欠覆盖，同时显著增加冲击区间宽度，说明极端状态不确定性需要以锐度为代价。

9.3 天气关联与恢复过程的解释边界

E2 的样条项和 E3 的多尺度衰减描述的是控制公共需求与日历变量后的条件关联。历史天气来自回溯重建，且需求与季节、通勤、节假日共同变化，因此本文不使用“温度导致需求上升”“降雨造成固定恢复时长”等因果表述。融合权重同样不是机制贡献率：例如 E6 在 6h shock 的 0.415 只表示该状态样本的加权预测较多使用其输出。

9.4 为什么保留六专家而不是只保留 E1+TCN

如果目标只是在当前最终期追求简洁，E1+TCN 已经是很有竞争力的简化模型。本文保留六专家完全体，是因为研究问题本身要求同时观察当前天气、恢复记忆、局部卷积、递归状态和注意力依赖在不同状态下如何被使用。各专家先在自己的候选设计中筛选，再经过增量消融、完整融合和 LOO 检验；这一流程避免先把所有参数塞进单体模型，再事后解释特征的重要性。完整模型取得最佳综合平均 MAE，但 LOO 同时揭示只有 E4、E5 具有跨时距稳定的正边际作用。由此得到的是透明的复杂度-性能权衡，而不是“专家越多越好”的结论。

10 局限与后续改进

1. **天气可用性**：Open-Meteo 为历史重建，不是实际发布预报。线上评价需要保存每个发布时刻真实可用的天气预报版本。
2. **缺少单体对照**：本文把全特征单模型的优化负担作为问题设定动机，但尚未在相同参数预算下训练该对照，因此不能把“多专家一定优于单体”外推为普遍规律。
3. **区间锐度代价**：状态分位数改善 shock 覆盖，但 90%/95% 平均宽度增加约 52%/49%。后续应研究状态收缩分位数、在线更新或更细粒度事件簇校准。
4. **外部有效性**：当前结论来自 Capital Bikeshare 的单一城市系统与 2025 年最终期，需要在不同城市、站点尺度和真实业务发布流中复核。

5. **工程统计不完整：**结构化专家的真实训练/推理时间和内存没有被记录，GPU也未启用，不能据此比较所有六个专家的计算效率。

11 结论

本文在不改变原始研究问题和发布时间边界的前提下，从单车使用过程包含异质机制这一新角度出发，把共享单车需求预测从三专家更新为六专家完整预测框架。六个专家分别承担需求动态、当前天气非线性、多尺度恢复、局部卷积时序、递归状态记忆和长距离注意力六种建模贡献。各类专家先在多种候选设计中筛选最佳配置，再通过独立增量消融检验贡献，最后共同进入完全体拟合。该流程用多个专门化模型降低单一模型吞并全部参数的负担，同时避免凭专家名称预设其有效性。

在 Capital Bikeshare 2025 年 4–12 月的最终评价中，六专家完全体在 1、2、3、6 小时的 MAE 为 75.691、97.794、116.644、129.372，四时距平均相对 E1 基座改善 31.56%，取得全部已测试配置中的最低平均 MAE。LOO 进一步确认 E4、E5 是跨时距稳定的核心贡献者，E2、E3、E6 则提供结构化解释或条件性补充。四种融合目标的开发期差异很小，预设 MSE 在最终期仍取得最低平均 MAE。状态分位数把 shock 覆盖拉回名义水平附近，但以区间显著变宽为代价。由此，当前最稳妥的结论不是“六专家在每个时距全面获胜”，而是：分而专之的多专家建模在综合平均意义上取得 best-of-all 拟合结果；其中统计专家保留清晰的问题角色，TCN 与 GRU 提供最稳定的预测增益，而融合与不确定性结果必须按时距和状态解释。

A 完全体状态权重明细

表 11：六专家在各时距和发布状态下的预测权重

<i>h</i>	状态	E1	E2	E3	E4	E5	E6
1	normal	0.036	0.092	0.000	0.272	0.471	0.129
1	shock	0.040	0.100	0.006	0.265	0.463	0.127
1	recovery	0.035	0.095	0.001	0.271	0.467	0.130
2	normal	0.000	0.000	0.000	0.407	0.254	0.340
2	shock	0.011	0.007	0.004	0.392	0.253	0.332
2	recovery	0.000	0.002	0.002	0.405	0.249	0.341
3	normal	0.000	0.002	0.000	0.331	0.254	0.413
3	shock	0.000	0.022	0.012	0.322	0.246	0.398
3	recovery	0.000	0.009	0.000	0.333	0.246	0.412
6	normal	0.000	0.000	0.004	0.308	0.281	0.407
6	shock	0.013	0.017	0.028	0.283	0.244	0.415
6	recovery	0.000	0.001	0.010	0.311	0.273	0.405

B 复现实验输出

本文主结果与确认实验对应以下运行和工件：

- 六专家冻结预测与基础增量结果： `artifacts/figure_inputs/`;
- LOO、融合目标和状态区间确认： `artifacts/confirmation_results/`;
- 确认实验来源运行： `runs/confirmation_final2_20260910_111616`（本地运行目录，不纳入 Git）。

关键校验记录显示：四个时距均存在；六个专家均进入完全体；融合权重和为一；LOO 重新拟合了校准层与融合层；状态区间只使用满足 $\text{target_time} \leq \text{issue_time}$ 的历史分数；所有结构和融合目标均在最终评价之前冻结。论文派生目录保存确认实验表、最终图和 provenance 文件，便于逐项核对正文数值。

参考文献

- [1] Friedman, J. H. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [2] Chen, T. and Guestrin, C. XGBoost: A Scalable Tree Boosting System. *KDD*, pp. 785–794, 2016.
- [3] Cameron, A. C. and Trivedi, P. K. *Regression Analysis of Count Data*. 2nd ed., Cambridge University Press, 2013.
- [4] Hastie, T. J. and Tibshirani, R. J. *Generalized Additive Models*. Chapman and Hall/CRC, 1990.
- [5] Bai, S., Kolter, J. Z., and Koltun, V. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv:1803.01271, 2018.
- [6] Cho, K. et al. Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. *EMNLP*, 2014.
- [7] Vaswani, A. et al. Attention Is All You Need. *NeurIPS*, 2017.
- [8] Jacobs, R. A., Jordan, M. I., Nowlan, S. J., and Hinton, G. E. Adaptive Mixtures of Local Experts. *Neural Computation*, 3(1):79–87, 1991.
- [9] Jordan, M. I. and Jacobs, R. A. Hierarchical Mixtures of Experts and the EM Algorithm. *Neural Computation*, 6(2):181–214, 1994.
- [10] Angelopoulos, A. N. and Bates, S. A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification. *Foundations and Trends in Machine Learning*, 16(4):494–591, 2023.
- [11] Capital Bikeshare. System Data: Trip History Data. <https://capitalbikeshare.com/system-data>. Accessed 2026-09-09.

- [12] Open-Meteo. Historical Weather API. <https://github.com/open-meteo/open-meteo/blob/main/openapi/historical-weather.yml>. Accessed 2026-09-09.